

AI GRID SUMMIT

# HANDS-ON RAG

Build your own document Q&A system

---

Felix Boelter | Mario Tormo Romero


AI Service Centre Berlin-Brandenburg | 14 October 2026

Gefördert durch:



Design IT.  
Create Knowledge.

[www.hpi.de](http://www.hpi.de)



# PARTICIPANT LIST

The list is going round now. Please sign in while everyone is still seated.

| Name | Institution | Email |
|------|-------------|-------|
|      |             |       |
|      |             |       |
|      |             |       |

The printout stays with the workshop lead. Please hand it back at the end.

## START THE INSTALL NOW

It downloads about 2 GB, so let it run while we talk.

```
git clone https://github.com/aihpi/workshop-rag-basics.git
cd workshop-rag-basics
uv sync
```



Needs uv and Git, from the  
workshop-getting-started guide.

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



01

# AI SERVICE CENTRE BERLIN-BRANDENBURG


---

Who we are and what you can use.

# FOUR AI SERVICE CENTRES



[hpi.de/ki-servicezentrum](https://hpi.de/ki-servicezentrum)



**KISSKI**  
KI-Servicezentrum für sensible  
und kritische Infrastrukturen

**Göttingen | Kassel | Hannover**

Sensitive and critical infrastructure, medicine & energy

**KI Service Zentrum**  
by Hasso-Plattner-Institut

**Potsdam | Berlin**

Education and consulting, AI in business & society

**WEST AI**  
KI-Servicezentrum

**Bonn | St. Augustin | Aachen | Jülich | Dortmund**

AI hardware, consulting and training; multimodal and transferable models

**hessian.AISC**

**Darmstadt**

Explainability, generalisability and contextual adaptation



**KI-Servicezentren**

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

**KI Service Zentrum**  
by Hasso-Plattner-Institut




**Goal: lower the barriers to putting AI to work in society and business**

# EDUCATION



Newsletter

## Talks



[tele-task.de/series/1463](https://tele-task.de/series/1463)

- Guest talks on research and innovation




## Workshops



[aimaker.community](https://aimaker.community)

- Hands-on topics
- For example: speech2summary, Docker for ML, semantic search





## MOOCs



[open.hpi.de/channels/ai-service-center](https://open.hpi.de/channels/ai-service-center)

- ChatGPT: what does generative AI mean for society?
- Profitable AI
- Understanding and avoiding AI bias



Gefördert durch:



**KI Service Zentrum**  
by Hasso-Plattner-Institut





# INFRASTRUCTURE



[aisc.hpi.de](https://aisc.hpi.de) · request access



- Access **free of charge**
- No production use
  - Data should be **anonymised or synthetic**
  - No **hosting of products**
- **Reporting & publication** by users
- **Existing rights** stay with users
- **New rights** stay with users
  - Usage rights granted for research and teaching

## Training

- 64 NVIDIA H100 GPUs

## Inference

- 40 NVIDIA A30 GPUs

## ARM server

- Ampere Altra Max M128-30 CPU
- 2× NVIDIA L40 GPUs

## GPU server

- AMD Epyc CPU
- 8× NVIDIA L40S GPUs

## Edge

- ARMv8 CPU
- NVIDIA Jetson AGX modules

## Neuromorphic

- 288 SpiNNaker2 chips

## Storage

- 1.5 PB NVRAM

## Network

- 400 Gb/s InfiniBand
- 200 Gb/s Ethernet

Gefördert durch:





# CONSULTING



Book office hours

## AI office hours

- AI infrastructure
- AI models & frameworks
- AI use cases

## AI pilot projects

- Co-developing a prototype
- Applications every three months
- Selection criteria such as AI maturity and public benefit
- Results are published

## Collaborations

- Jointly organised network meetings

## Past AI pilot projects

- Generating maths problems
- Generating plain language
- Generating upcycling ideas
- Reducing food waste
- Dating documents by handwriting



Apply now!

# BY 1:45 YOU HAVE

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



- 1 A chatbot on your laptop that answers from your own PDF.
- 2 Every claim links to the page it came from, with a score that says how well it is backed.
- 3 A list of what to check before you trust it.

## AGENDA

|                        |          |               |            |       |                 |                         |      |
|------------------------|----------|---------------|------------|-------|-----------------|-------------------------|------|
| 0:00                   | 0:22     | 0:35          | 0:48       | 1:01  | 1:06            | 1:22                    | 1:40 |
| Welcome · AISC · setup | 1 · Chat | 2 · Documents | 3 · Search | Break | 4 · RAG + score | 5 · Your PDF · transfer | Q&A  |

Every notebook block: a minute of slides, then the notebook (time-boxed), then a quick check.




# ARCHITECTURE

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



**Once, ahead of time,** the documents are read and cut into chunks. The embedding model turns every chunk into a vector, a list of numbers that captures its meaning. The vectors go into the vector database.

**For every question,** the same model turns the question into a vector and searches the same database. The closest chunks go to the language model with the question, and it answers with sources.

# SETUP

## 1 Install (started on slide 2)

```
git clone https://github.com/aihpi/workshop-rag-basics.git
cd workshop-rag-basics
uv sync
```

## 2 Add the key

```
cp .env.example .env
open -e .env      # Windows: notepad .env
# paste the key from the whiteboard after LLM_API_KEY=
```

## 3 Check, and fetch Docling's models

```
uv run python check_setup.py
```

## 4 Start

```
uv run jupyter lab
```


Done when check\_setup.py prints **You're ready for the workshop.**

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



Cells that start with `%%writefile app.py` write the chatbot. Chainlit notices the change and reloads it in your browser at `localhost:8000`.

### CHAT MODEL

gemma-4-31b

### EMBEDDING MODEL

octen-embedding-8b

### RUNS ON

our own infrastructure in Potsdam

# TALKING TO AN LLM

## NOTEBOOK 1 · 6 MIN

### IN THIS NOTEBOOK

- Connect to the model through the gateway
- Ask about a detail from one of our papers
- Build a chatbot that remembers and streams

### YOUR TURN · IN THE CHATBOT · + ONLY IF TIME

1 Personality: change the system prompt

+ Bonus: show how long each answer took

Solutions are folded away under each exercise.

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



```
localhost:8000
```

In Kage et al. (2018), what were the lifetime-encoded beads loaded with, and which lifetimes did they have?

✓ The model answers. Would you rely on it?



# WOULD YOU RELY ON IT?

Hands up.  
Remember your letter.

## NOTEBOOK 1

The model answered the Kage question. Would you rely on this answer?

- A yes, as it is
- B yes, after a quick check
- C no

CHECKPOINT

Gefördert durch:



KI Service  
Zentrum  
by Hasso-Plattner-Institut



# HALF RIGHT, AND YOU CAN'T TELL WHICH HALF

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut

HPI

01

## No access to your documents

Language models are trained mostly on public data. Your lab reports and paywalled papers are unknown to them.

02

## Similar instead of right

When the right information is missing, the model falls back on related material: values from similar papers end up in the answer about yours.

03

## RAG decides what the answer is built on

Retrieval-augmented generation sets which documents an answer may use, and cites the page.

# READING DOCUMENTS



NOTEBOOK 2 · 7 MIN

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



A PDF stores where to draw each letter. Docling finds headings, paragraphs and tables, and writes Markdown.

First every 1000 characters, neighbours sharing 200. Then Docling cuts at headings, paragraphs and table rows.

YOUR TURN · + ONLY IF TIME

1 Where are the cuts? 300 and 3000, in the notebook

+ Bonus: only the tables, in the chatbot



# WHAT DID YOU FIND?

Vote by show of hands.  
Answers on the next slide.

## NOTEBOOK 2

**What happened to the tables when Docling read the papers?**

- A They were dropped
- B They became loose lines of numbers
- C They stayed tables, in Markdown

## NOTEBOOK 2 · YOUR TURN

**What happens with smaller chunks, 300 characters instead of 1000?**

- A Fewer chunks, and tables stay whole
- B More chunks, and more of them cut through a table
- C Nothing changes

# WHAT WE FOUND

## NOTEBOOK 2

What happened to the tables when Docling read the papers?

### **C** They stayed tables, in Markdown

All 5 tables in the three papers came through with their rows and columns, searchable like any other text.

## NOTEBOOK 2 · YOUR TURN

What happens with smaller chunks, 300 characters instead of 1000?

### **B** More chunks, and more of them cut through a table

1434 chunks instead of 197, so more borders fall inside a table. Docling's chunker cuts between rows instead.

## NEXT

We have good chunks. How do we find the right ones for a question?

# SEARCH

## NOTEBOOK 3 · 8 MIN

### IN THIS NOTEBOOK

- Embed sentences and compare how similar they are
- Store all chunks in Qdrant, in memory
- Turn the bot into a search engine, no LLM yet

### YOUR TURN · IN THE CHATBOT · + ONLY IF TIME

**1** Fewer, better results: pick a score cutoff

**+** Bonus: ask in German

Solutions are folded away under each exercise.

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut

HPI

localhost:8000

What were the lifetime-encoded beads loaded with?

Kage\_2018\_SciReports.pdf, p. 2 (score 0.76)  
› ... loaded with different organic fluorophores ...

Kage\_2018\_SciReports.pdf, p. 3 (score 0.62)  
› Table 1. Lifetime codes and respective luminophores ...

What is the capital of France?

Schmidt\_2022\_SciReports.pdf, p. 8 (score 0.17) ...

# WHY DID FRANCE GET A HIT?

Gefördert durch:




Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



Similar meaning → arrows point the same way.



Similarity: 1 = same direction. Compare scores with each other, not with 1.  
Real embeddings have 4096 dimensions; this drawing has 2.

## Collection "papers"

| id | VECTOR                      | PAYLOAD                           |
|----|-----------------------------|-----------------------------------|
| 0  | [0.012, -0.031, 0.087, ...] | Kage_2018 · p. 1 · "Time-res..."  |
| 1  | [-0.007, 0.044, 0.019, ...] | Kage_2018 · p. 1 · "multiplex..." |
| 2  | [0.021, 0.003, -0.058, ...] | Kage_2018 · p. 2 · "are loade..." |

... 206 points, one per chunk

query\_points

**Question → vector**  
embedded like the chunks

returns

**5 closest points**  
each with score + payload

vector = what Qdrant searches by

payload = what you get back

- 1 An embedding model turns text into a list of numbers, 4096 with ours. Similar meaning, similar direction.
- 2 Search returns the closest chunks, however far away they are.
- 3 Qdrant stores one point per chunk: the vector, and a payload with text, file and page.



Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



# BREAK

---

5 minutes. Behind? Finish notebook 3 now: notebook 4 needs its index.json.

# RETRIEVAL-AUGMENTED GENERATION

NOTEBOOK 4 · 11 MIN

## RETRIEVE

the 5 closest chunks

## AUGMENT

the prompt with them, numbered [1] to [5]

## GENERATE

the answer, citing those numbers

Every [n] leads to a chunk, and every chunk remembers its file and page.

YOUR TURN · + ONLY IF TIME

1 How much context? 2 chunks instead of 5

+ Bonus: strict or not

+ Bonus: show the evidence; follow-up questions

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



### WHAT THE LLM RECEIVES

system

Answer only from the context. If it isn't there, say you don't know.

user

Context:

[1] ...microbeads are loaded with different organic...

[2] ...tailor-made melamine beads with a polyelectr...

:

[5] ...imitations of lifetime encoding in flow with...

Question: what were the beads loaded with?

LLM  
gemma-4-31b

The beads were loaded  
with different organic  
fluorophores with  
lifetimes in the  
nanosecond range [1].

green: the 5 chunks Qdrant found · blue: what you typed

localhost:8000

What were the beads in Kage et al. loaded with?

✓ The answer cites [1], [2]. Compare it with notebook 1.

# WOULD YOU STILL RELY ON IT?

## THE NOTEBOOK 1 ANSWER, JUDGED IN NOTEBOOK 4 (ONE RUN)

- ✓ The beads were loaded with quantum dots (QDs).
- ✗ Three different types of quantum dots, to create distinct lifetime signatures.
- ✗ One type had a short lifetime of about 10 ns.
- ✗ One type had a medium lifetime of about 25 ns.
- ✗ One type had a long lifetime of about 50 ns.
- ✗ The beads were used as fiducial markers to correct for drift during imaging.

faithfulness **0.17**

## WHAT THE PAPER SAYS · TABLE 1, PAGE 3

Organic dyes in PMMA beads

**1.7 to 7.9 ns**

Quantum dots in melamine beads

**22.6 ns**

**With RAG you don't read the paper either: click [1], and page 3 opens.**

Gefördert durch:



**KI** Service  
Zentrum  
by Hasso-Plattner-Institut



# PUTTING IT TOGETHER

NOTEBOOK 5 · 6 MIN

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut




YOUR TURN · IN THE CHATBOT · + ONLY IF TIME

**1** Your own document: attach a PDF, ask, check the page and the score

**+** Bonus: chat with this document only

ONCE, AHEAD OF TIME



searches the same collection

FOR EVERY QUESTION



□ data   □ processing step   □ AI model   □ vector database

PIECE · NOTEBOOK

Read a PDF with Docling

**2**

Cut into chunks

**2**

Turn text into vectors

**3**

Store and search in Qdrant

**3**

Answer from the chunks

**4**

Cite the page

**4**

Score the answer

**4**

Your own PDF

**5**

**Your PDF goes to the AISC gateway in Potsdam. Test or public documents only.**

# YOUR OWN DOCUMENTS

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



## QUESTION 1

**Which documents would you use  
this for?**

## QUESTION 2

**What do you expect to go wrong  
first, and why?**

One sentence each, round the room.



# YOUR OWN DOCUMENTS

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



## QUESTION 1

**Which documents would you use  
this for?**

## QUESTION 2

**What do you expect to go wrong  
first, and why?**

WHAT OFTEN GOES WRONG   Scanned PDFs · tables · questions across several documents

BEFORE YOU TRUST AN ANSWER · THE LIST IS AT THE END OF NOTEBOOK 5

- |                                                    |                                                 |                                                     |
|----------------------------------------------------|-------------------------------------------------|-----------------------------------------------------|
| <b>1</b> Click the source                          | <b>2</b> Low score: check the X claims          | <b>3</b> High score: still check what's missing     |
| <b>4</b> Scanned PDF or tables? Check what went in | <b>5</b> Several documents? Search may miss one | <b>6</b> Costly if wrong? Keep "say you don't know" |

# WHERE TO TAKE THIS

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



## Today

One chunker for every file

Qdrant in memory, rebuilt on every start

Vector search only

Faithfulness, one answer at a time

## The template

A chunker per data source, set in a config file

Qdrant server, ingested once, updated when files change

Hybrid search: vectors plus keyword matching

An evaluation app that compares setups



### The template

aihpi/pilotproject-rag-template on  
GitHub



### Office hours

Stuck on your own collection? Book a  
slot.



### Pilot projects

Build it with us; applications every three  
months.

Gefördert durch:



# YOUR FEEDBACK COUNTS

We shape our next workshops around your answers. Two minutes is enough.



[kisz@hpi.de](mailto:kisz@hpi.de)

[hpi.de/kisz](https://hpi.de/kisz)

Felix Boelter | Mario Tormo Romero


## KEEP GOING

[github.com/aihpi/workshop-rag-basics](https://github.com/aihpi/workshop-rag-basics) · this workshop

[github.com/aihpi/pilotproject-rag-template](https://github.com/aihpi/pilotproject-rag-template) · template

**Design IT.  
Create Knowledge.**

[www.hpi.de](https://www.hpi.de)



Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



# APPENDIX

---

Background for questions. Not part of the main path.

# RAG IN PRACTICE

### Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Fachfrage

Themenüberblick

Beantwortet eine konkrete Frage mit Quellenbezug

Wann tritt ETS 2 in Kraft?

Filter

Suchen

Systemanweisung anzeigen

QUELLEN (3)

1

Emissionshandelsystem und Klimaschutz

WD 5 - 3000 - 009/25

26.05.2025

2

Die Lootbox im deutschen Recht und im europäischen Vergleich

WD 1 - 3000 - 019/24

17.10.2024

3

Zur Ersteinschätzung in Notaufnahmen von Krankenhäusern

WD 9 - 3000 - 068/23

23.11.2023

## SENTRA

Research Services of the German Bundestag: semantic search across expert reports, an AI summary, every statement traced to its report.

[github.com/aihpi/pilotproject-sentra](https://github.com/aihpi/pilotproject-sentra)

Semantic search · an AI summary · sources for transparency. Today you build the same thing, small.

Gefördert durch:

Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

Service  
Zentrum  
by Hasso-Plattner-Institut

Was ist der Unterschied zwischen Prozess- und Systembausteinen?

Used rag\_retrieve

Prozess-bausteine beschreiben **Methoden, Abläufe und organisatorische Maßnahmen** des Informationssicherheits-Managements. Sie sind nach den Schichten ISMS, ORP, CON, OPS und DER gegliedert und geben jeweils Gefährdungs- sowie Anforderungsübersichten für die jeweiligen Prozesse (z. B. Risikomanagement, Notfall- und Incident-Response) (

QUELLE 1: IT-GRUNDSCHUTZ-BAUSTEINE (S.21) ).

System-bausteine dagegen fokussieren auf **technische Komponenten und deren Umgebung**. Sie ordnen sich den Schichten INF, NET, SYS, APP und IND zu und enthalten Beschreibungen von Infrastruktur-, Netzwerk-, System-, Anwendungs- und Industrie-IT Komponenten samt zugehöriger Gefährdungen und konkreter Sicherheits-anforderungen ( QUELLE 2: DIE IT-GRUNDSCHUTZ-BAUSTEINE (S.132-133) ).

Beide Bausteintypen sind modular aufgebaut, ermöglichen eine gezielte **Bausteinauswahl** und bilden zusammen das Schichten-Modell des IT-Grundschutz-Kompendiums (

QUELLE 3: BAUSTEINE (S.35) ).

**Bezug zu Ihren Interessen:** Der Unterschied ist zentral für Ihre Arbeit an Prozess- und System-bausteinen sowie bei der Auswahl passender Bausteine im Informationsverbund.

Quellen anzeigen

Welche Kriterien nutzen Sie üblicherweise bei der Auswahl von Prozess-bausteinen für Ihr ISMS?

Wie integrieren Sie System-bausteine in die G... tarchitektur Ihres Informationsverbundes?

Type your message here...

Nutze ~/export all\* um alle Chats zu exportieren.

LLMs can make mistakes. Check important info.

## GrundschutzKI

IT baseline protection: questions in plain language, a short answer with a jump link, the BSI original open next to it.

[github.com/aihpi/pilotprojekt-GrundschutzKI](https://github.com/aihpi/pilotprojekt-GrundschutzKI)

Readme

Einstellungen

Workshop-Code

Quelle 1: IT-Grundschutz-Bausteine (S.21)

### IT-Grundschutz – Basis für Informationssicherheit

- für die Verwendung bei der Risikoanalyse optimiert.
- produktneutral (neutral), technisch-neutral (neutral), bestimmte Techniken prägen so stark den Markt, dass sie auch die abstrahierten Gefährdungen beeinflussen).
- kompatibel mit vergleichbaren internationalen Katalogen und Standards und
- nahtlos in den IT-Grundschutz integriert.

#### IT-Grundschutz-Bausteine

Die Bausteine des IT-Grundschutz-Kompendiums enthalten jeweils eine Beschreibung der betrachteten Komponente, Vorgehensweisen und IT-Systeme, gefolgt von einem kurzen Überblick über spezifische Gefährdungen sowie konkreter Anforderungen, um das Zielobjekt abzusichern.

#### Aufbau der Bausteine

Die zentrale Rolle des IT-Grundschutz-Kompendiums spielen die einzelnen Bausteine, deren Aufbau jeweils gleich ist. Zunächst wird jeweils das betrachtete Zielobjekt allgemein beschrieben. Die folgende Zielsetzung formuliert, welcher Sicherheitsgewinn mit der Umsetzung eines IT-Grundschutz-Bausteins erreicht werden soll. Danach folgt das Kapitel *Abgrenzung und Modellierung*. Hier erfolgt eine Abgrenzung der Aspekte, die nicht im jeweiligen Baustein behandelt werden, sowie Verweise auf andere Bausteine, die diese Aspekte aufgreifen. Neben der Abgrenzung werden in diesem Kapitel auch Modellierungshinweise für den konkreten Baustein aufgeführt.

Im Anschluss werden spezifische Gefährdungen aufgeführt. Sie erheben keinen Anspruch auf Vollständigkeit, liefern aber ein Bild über die Sicherheitsprobleme, die ohne Gegenmaßnahmen beim Einsatz der betrachteten Komponente, Vorgehensweisen oder des betrachteten IT-Systems entstehen können. Die Fiktionierung der möglichen Risiken kann noch stärker für das Thema sensibilisieren. Bei der Risikoanalyse, die jedem Baustein zugrunde liegt, wurden die spezifischen Gefährdungen aus den elementaren Gefährdungen abgeleitet. Anforderungen, die gegen diese Gefährdungen wirken, sind in der Regel im selben Baustein zu finden, in einigen Fällen sind aber zusätzliche Anforderungen aus anderen Bausteinen zu berücksichtigen.

Auf die spezifischen Gefährdungen folgen in der Bausteinstruktur die Anforderungen. Diese sind in drei Kategorien gegliedert: Basis- und Standard-Anforderungen sowie Anforderungen bei erhöhtem Schutzbedarf. Basis-Anforderungen sind vorrangig umzusetzen, da sie mit geringem Aufwand den größtmöglichen Nutzen erzielen. Gemeinsam mit den Basis-Anforderungen erfüllen die Standard-Anforderungen den Stand der Technik und adressieren den normalen Schutzbedarf. Ergänzend dazu bieten die Bausteine des IT-Grundschutz-Kompendiums Vorschläge für Anforderungen bei erhöhtem Schutzbedarf. Zur Referenzierung sind die Anforderungen bauteinübergreifend eindeutig nummeriert, z. B. SYS 3.4.A2. Über dieses Schema wird zunächst die Schicht (im Beispiel „SYS“) benannt, dann die Nummer der jeweiligen Teilschichten und des Bausteins (im Beispiel „3.4“) und schließlich die Anforderung selbst (im Beispiel „A2“). Gibt es passende Umsetzungshinweise, trägt die dort aufgeführte Maßnahme zu einer Anforderung „A“ die gleiche Nummer mit einem vorangestellten Buchstaben „M“, im Beispiel also „SYS 3.4.M2“.

In jedem Baustein wird beschrieben, wer für dessen Umsetzung zuständig ist. Es ist immer eine grundsätzlich zuständige Rolle benannt. Daneben kann es weitere Rollen geben, die für die Umsetzung von Anforderungen zuständig sind. Diese werden dann jeweils im Titel der Anforderung in eckigen Klammern genannt. Der oder die Informationssicherheitsbeauftragte (ISB) ist bei strategischen Entscheidungen stets einzubeziehen. Außerdem ist der oder die ISB für zuständig, dass alle Anforderungen gemäß dem festgelegten Sicherheitskonzept erfüllt und überprüft werden.

In den Überschriften der Anforderungen werden die Anforderungsteile neben den zu beteiligenden Rollen um ein Kürzel ergänzt, um auch außerhalb des Kontexts des jeweiligen Bausteins direkt ersichtlich zu machen, ob es sich um eine „Basis-Anforderung“ (B), eine „Standard-Anforderung“ (S) oder eine „Anforderung bei erhöhtem Schutzbedarf“ (H) handelt.

Am Ende der Bausteine sind weiterführende Informationen und Verweise aufgeführt. Ergänzt werden die Bausteine zudem in einem Anhang um eine sogenannte Kreuzverweisstabelle, in der den Anforderungen die betreffenden elementaren Gefährdungen zugeordnet werden. Diese Zuordnung kann für eine Risikoanalyse genutzt werden.

28



# FROM DOCUMENT TO CHUNKS

Gefördert durch:




Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut




## STEP 1 · DOCLING READS THE PAGE



A PDF only stores where to draw each letter. Docling finds headings, paragraphs, tables and figures, and writes Markdown.

## STEP 2 · CUT INTO CHUNKS



**Fixed size:** every 1000 characters, with 200 overlap. Simple, the same for every document, but it may cut through a table.

**Our notebook:** Docling's HybridChunker, at headings, paragraphs and table rows, below 256 tokens.

**GrundschutzKI:** at every heading, because the BSI standards are clearly structured. A chunk keeps its title.

# PROMPT AND CITATIONS

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



## RETRIEVE

the 5 closest chunks

## AUGMENT

the prompt with them, numbered [1] to [5]

## GENERATE

the answer, citing those numbers

Every [n] leads back to a chunk, and every chunk remembers its file and page. That is all a citation is.

### WHAT THE LLM RECEIVES

#### system

Answer only from the context. If it isn't there, say you don't know.

#### user

Context:

[1] ...microbeads are loaded with different organic...

[2] ...tailor-made melamine beads with a polyelectr...

⋮

[5] ...imitations of lifetime encoding in flow with...

Question: what were the beads loaded with?

#### LLM

gemma-4-31b

The beads were loaded  
with different organic  
fluorophores with  
lifetimes in the  
nanosecond range [1].

green: the 5 chunks Qdrant found · blue: what you typed

...loaded with different  
organic fluorophores  
in the nanosecond  
range [1]

finds [1]

```
hits[0].payload
source: Kage_2018_...pdf
page: 2
```

cl.Pdf

opens at page 2

The number in the answer points into the list of chunks, and every chunk remembers its file and page.

# IS THE ANSWER ANY GOOD?

Gefördert durch:



Bundesministerium  
für Forschung, Technologie  
und Raumfahrt

KI Service  
Zentrum  
by Hasso-Plattner-Institut



You scored faithfulness in notebook 4. Changed the chunk size or the number of chunks? Measure whether it helped. Neither score needs a hand-written correct answer.

## Faithfulness

Is every claim backed by the retrieved chunks?

```
supported claims ÷ all claims
```

A judge model splits the answer into claims and checks each one against the chunks. 0.5 means half the claims have no source.

## Relevance

Does the answer address the question?

```
similarity(questions from the answer, real question)
```

A judge model writes the questions this answer would fit; their embeddings are compared with the question that was asked.

**In the template:** both scores for every answer, a badge in the chat, and an evaluation app that compares configurations. Built on Ragas.