

[EVENT]

BUILD A RAG CHATBOT

AI-assisted research on your own documents

[Presenter]


AI Service Centre Berlin-Brandenburg | [Date]

Gefördert durch:



Design IT.
Create Knowledge.

www.hpi.de



PARTICIPANT LIST

The list is going round now. Please sign in while everyone is still seated.

Name	Institution	Email



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut



The printout stays with the workshop lead. Please hand it back at the end.

AGENDA · 90 MINUTES

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut



0:00	 Slides	Welcome, the AI Service Centre, why RAG	10 min
0:10	 Slides	Architecture and setup	5 min
0:15	 Notebook 1	Talking to an LLM	10 min
0:25	 Slides + notebook 2	From document to chunks · reading documents	13 min
0:38	 Slides	What we found so far · embeddings and vector search	7 min
0:45	 Notebook 3	Search	13 min
0:58	 Slides + notebook 4	Prompt and citations · retrieval-augmented generation	16 min
1:14	 Notebook 5	Putting it together	10 min
1:24	 Slides	Where to go next, feedback	6 min



 notebooks, hands-on: 56 min  theory  welcome and wrap-up

01

AI SERVICE CENTRE BERLIN-BRANDENBURG

Who we are and what you can use.

Gefördert durch:




Bundesministerium
für Forschung, Technologie
und Raumfahrt

FOUR AI SERVICE CENTRES



hpi.de/ki-servicezentrum



KISSKI
KI-Servicezentrum für sensible
und kritische Infrastrukturen

Göttingen | Kassel | Hannover

Sensitive and critical infrastructure, medicine & energy

KI Service Zentrum
by Hasso-Plattner-Institut

Potsdam | Berlin

Education and consulting, AI in business & society

WEST AI
KI-Servicezentrum

Bonn | St. Augustin | Aachen | Jülich | Dortmund

AI hardware, consulting and training; multimodal and transferable models

hessian.AISC

Darmstadt

Explainability, generalisability and contextual adaptation



KI-Servicezentren

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service Zentrum
by Hasso-Plattner-Institut




Goal: lower the barriers to putting AI to work in society and business

EDUCATION



Newsletter

Talks



tele-task.de/series/1463

- Guest talks on research and innovation




Workshops



aimaker.community

- Hands-on topics
- For example: speech2summary, Docker for ML, semantic search




MOOCs



open.hpi.de/channels/ai-service-center

- ChatGPT: what does generative AI mean for society?
- Profitable AI
- Understanding and avoiding AI bias



INFRASTRUCTURE



aisc.hpi.de · request access



- Access **free of charge**
- No production use
 - Data should be **anonymised or synthetic**
 - No **hosting of products**
- **Reporting & publication** by users
- **Existing rights** stay with users
- **New rights** stay with users
 - Usage rights granted for research and teaching

Training

- 64 NVIDIA H100 GPUs

Inference

- 40 NVIDIA A30 GPUs

ARM server

- Ampere Altra Max M128-30 CPU
- 2× NVIDIA L40 GPUs

GPU server

- AMD Epyc CPU
- 8× NVIDIA L40S GPUs

Edge

- ARMv8 CPU
- NVIDIA Jetson AGX modules

Neuromorphic

- 288 SpiNNaker2 chips

Storage

- 1.5 PB NVRAM

Network

- 400 Gb/s InfiniBand
- 200 Gb/s Ethernet

CONSULTING



Book office hours

AI office hours

- AI infrastructure
- AI models & frameworks
- AI use cases

AI pilot projects

- Co-developing a prototype
- Applications every three months
- Selection criteria such as AI maturity and public benefit
- Results are published

Collaborations

- Jointly organised network meetings

Past AI pilot projects

- Generating maths problems
- Generating plain language
- Generating upcycling ideas
- Reducing food waste
- Dating documents by handwriting



Apply now!

02

MOTIVATION

What language models don't know, and what that means for research.

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

WHY A LANGUAGE MODEL ALONE IS NOT ENOUGH

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut

HPI

01

No access to your own data

Language models are trained mostly on public data. Internal documents about your processes and paywalled specialist publications are unknown to them.

02

Similar instead of right

When the right information is missing, the model falls back on related material: the rules for no-parking zones answer a question about no-stopping zones, popular science stands in for the specialist literature.

03

RAG decides what the answer is built on

Retrieval-augmented generation sets which documents an answer may use, and shows which source every statement comes from.

RAG IN PRACTICE

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Fachfrage

Themenüberblick

Beantwortet eine konkrete Frage mit Quellenbezug

Wann tritt ETS 2 in Kraft?

Filter

Suchen

Systemanweisung anzeigen

QUELLEN (3)

1

Emissionshandelsystem und Klimaschutz

WD 5 - 3000 - 009/25

26.05.2025

2

Die Lootbox im deutschen Recht und im europäischen Vergleich

WD 1 - 3000 - 019/24

17.10.2024

3

Zur Ersteinschätzung in Notaufnahmen von Krankenhäusern

WD 9 - 3000 - 068/23

23.11.2023

SENTRA

Research Services of the German Bundestag: semantic search across expert reports, an AI summary, every statement traced to its report.

github.com/aihpi/pilotproject-sentra

Semantic search · an AI summary · sources for transparency. Today you build the same thing, small.

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und Raumfahrt

Service
Zentrum
by Hasso-Plattner-Institut

Was ist der Unterschied zwischen Prozess- und Systembausteinen?

Used rag_retrieve

Prozess-bausteine beschreiben **Methoden, Abläufe und organisatorische Maßnahmen** des Informationssicherheits-Managements. Sie sind nach den Schichten ISMS, ORP, CON, OPS und DER gegliedert und geben jeweils Gefährdungs- sowie Anforderungsübersichten für die jeweiligen Prozesse (z. B. Risikomanagement, Notfall- und Incident-Response) (

QUELLE 1: IT-GRUNDSCHUTZ-BAUSTEINE (S.21)).

System-bausteine dagegen fokussieren auf **technische Komponenten und deren Umgebung**. Sie ordnen sich den Schichten INF, NET, SYS, APP und IND zu und enthalten Beschreibungen von Infrastruktur-, Netzwerk-, System-, Anwendungs- und Industrie-IT Komponenten samt zugehöriger Gefährdungen und konkreter Sicherheits-anforderungen (QUELLE 2: DIE IT-GRUNDSCHUTZ-BAUSTEINE (S.132-133)).

Beide Bausteintypen sind modular aufgebaut, ermöglichen eine gezielte **Bausteinauswahl** und bilden zusammen das Schichten-Modell des IT-Grundschutz-Kompendiums (

QUELLE 3: BAUSTEINE (S.35)).

Bezug zu Ihren Interessen: Der Unterschied ist zentral für Ihre Arbeit an Prozess- und System-bausteinen sowie bei der Auswahl passender Bausteine im Informationsverbund.

Quellen anzeigen

Welche Kriterien nutzen Sie üblicherweise bei der Auswahl von Prozess-bausteinen für Ihr ISMS?

Wie integrieren Sie System-bausteine in die G... tarchitektur Ihres Informationsverbundes?

Type your message here...

Nutze "/export all" um alle Chats zu exportieren.

LLMs can make mistakes. Check important info.

GrundschutzKI

IT baseline protection: questions in plain language, a short answer with a jump link, the BSI original open next to it.

github.com/aihpi/pilotprojekt-GrundschutzKI

Readme

Einstellungen

Workshop-Code

A

Quelle 1: IT-Grundschutz-Bausteine (S.21)

- für die Verwendung bei der Risikoanalyse optimiert.
- produktneutral (neutral), technisch neutral (neutral), bestimmte Techniken prägen so stark den Markt, dass sie auch die abstrahierten Gefährdungen beeinflussen).
- kompatibel mit vergleichbaren internationalen Katalogen und Standards und
- nahtlos in den IT-Grundschutz integriert.

IT-Grundschutz-Bausteine

Die Bausteine des IT-Grundschutz-Kompendiums erhalten jeweils eine Beschreibung der betrachteten Komponente, Vorgehensweisen und IT-Systeme, gefolgt von einem kurzen Überblick über spezifische Gefährdungen sowie konkreter Anforderungen, um das Zielobjekt abzusichern.

Aufbau der Bausteine

Die zentrale Rolle des IT-Grundschutz-Kompendiums spielen die einzelnen Bausteine, deren Aufbau jeweils gleich ist. Zunächst wird jeweils das betrachtete Zielobjekt allgemein beschrieben. Die folgende Zielsetzung formuliert, welcher Sicherheitsgewinn mit der Umsetzung eines IT-Grundschutz-Bausteins erreicht werden soll. Danach folgt das Kapitel *Abgrenzung und Modellierung*. Hier erfolgt eine Abgrenzung der Aspekte, die nicht im jeweiligen Baustein behandelt werden, sowie Verweise auf andere Bausteine, die diese Aspekte aufgreifen. Neben der Abgrenzung werden in diesem Kapitel auch Modellierungshinweise für den konkreten Baustein aufgeführt.

Im Anschluss werden spezifische Gefährdungen aufgeführt. Sie erheben keinen Anspruch auf Vollständigkeit, liefern aber ein Bild über die Sicherheitsprobleme, die ohne Gegenmaßnahmen beim Einsatz der betrachteten Komponente, Vorgehensweise oder des betrachteten IT-Systems entstehen können. Die Erfüllung der möglichen Risiken kann noch stärker für das Thema sensibilisieren. Bei der Risikoanalyse, die jedem Baustein zugrunde liegt, wurden die spezifischen Gefährdungen aus den elementaren Gefährdungen abgeleitet. Anforderungen, die gegen diese Gefährdungen wirken, sind in der Regel im selben Baustein zu finden, in einigen Fällen sind aber zusätzliche Anforderungen aus anderen Bausteinen zu berücksichtigen.

Auf die spezifischen Gefährdungen folgen in der Bausteinstruktur die Anforderungen. Diese sind in drei Kategorien gegliedert: Basis- und Standard-Anforderungen sowie Anforderungen bei erhöhtem Schutzbedarf. Basis-Anforderungen sind vorrangig umzusetzen, da sie mit geringem Aufwand den größtmöglichen Nutzen erzielen. Gemeinsam mit den Basis-Anforderungen erfüllen die Standard-Anforderungen den Stand der Technik und adressieren den normalen Schutzbedarf. Ergänzend dazu bieten die Bausteine des IT-Grundschutz-Kompendiums Vorschläge für Anforderungen bei erhöhtem Schutzbedarf. Zur Referenzierung sind die Anforderungen bauteinübergreifend eindeutig nummeriert, z. B. SYS 3.4.A2. Über dieses Schema wird zunächst die Schicht (im Beispiel „SYS“) benannt, dann die Nummer der jeweiligen Teilschichten und des Bausteins (im Beispiel „3.4“) und schließlich die Anforderung selbst (im Beispiel „A2“). Gibt es passende Umsetzungshinweise, trägt die dort aufgeführte Maßnahme zu einer Anforderung „A“ die gleiche Nummer mit einem vorangestellten Buchstaben „M“, im Beispiel also „SYS 3.4.M2“.

In jedem Baustein wird beschrieben, wer für dessen Umsetzung zuständig ist. Es ist immer eine grundsätzlich zuständige Rolle benannt. Daneben kann es weitere Rollen geben, die für die Umsetzung von Anforderungen zuständig sind. Diese werden dann jeweils im Titel der Anforderung in eckigen Klammern genannt. Der oder die Informationssicherheitsbeauftragte (ISB) ist bei strategischen Entscheidungen stets einzubeziehen. Außerdem ist der oder die ISB für zuständig, dass alle Anforderungen gemäß dem festgelegten Sicherheitskonzept erfüllt und überprüft werden.

In den Überschriften der Anforderungen werden die Anforderungsteile neben den zu beteiligenden Rollen um ein Kürzel ergänzt, um auch außerhalb des Kontexts des jeweiligen Bausteins direkt ersichtlich zu machen, ob es sich um eine „Basis-Anforderung“ (B), eine „Standard-Anforderung“ (S) oder eine „Anforderung bei erhöhtem Schutzbedarf“ (H) handelt.

Am Ende der Bausteine sind weiterführende Informationen und Verweise aufgeführt. Ergänzt werden die Bausteine zudem in einem Anhang um eine sogenannte Kreuzverweisstabelle, in der den Anforderungen die betreffenden elementaren Gefährdungen zugeordnet werden. Diese Zuordnung kann für eine Risikoanalyse genutzt werden.

11

03

BUILD IT YOURSELF

Five notebooks, one chatbot. A little theory before each.

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

ARCHITECTURE


Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut

HPI



Once, ahead of time, the documents are read and cut into chunks. The embedding model turns every chunk into a vector, a list of numbers that captures its meaning. The vectors go into the vector database.

For every question, the same model turns the question into a vector and searches the same database. The closest chunks go to the language model with the question, and it answers with sources.

SETUP

1 Get the code

```
git clone https://github.com/aihpi/workshop-rag-basics.git
cd workshop-rag-basics/workshop
```



aihpi/workshop-rag-basics

2 Install

```
uv sync
```

3 Add your key

```
cp .env.example .env # then paste the key
```

4 Check

```
uv run python check_setup.py
```

5 Start


```
uv run jupyter lab
```

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut



Cells that start with `%%writefile app.py` write the chatbot. Chainlit notices the change and reloads it in your browser at `localhost:8000`.

CHAT MODEL

gemma-4-31b

EMBEDDING MODEL

octen-embedding-8b

RUNS ON

our own infrastructure in Potsdam

TALKING TO AN LLM

NOTEBOOK 1 · 10 MIN

IN THIS NOTEBOOK

- Connect to the model through the gateway
- Ask about a paper the model has never seen
- Build a chatbot that remembers and streams

YOUR TURN · IN THE CHATBOT

- 1 Personality: change the system prompt
- 2 Starter buttons with `@cl.set_starters`
- 3 Stopwatch: show how long each answer took

Solutions are folded away under each exercise.

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut



```
localhost:8000
```

In Kage et al. (2018), what were the lifetime-encoded beads loaded with?

The beads were loaded with quantum dots (QDs), with lifetimes of about 2.5 ns, 10 ns and 25 ns.

✓ Sounds sure. It's wrong: the paper used organic dyes and quantum dots, with lifetimes from 1.7 to 22.6 ns.

FROM DOCUMENT TO CHUNKS

Gefördert durch:




Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut




STEP 1 · DOCLING READS THE PAGE



A PDF only stores where to draw each letter. Docling finds headings, paragraphs, tables and figures, and writes Markdown.

STEP 2 · CUT INTO CHUNKS



Our notebook: every 1000 characters, with 200 overlap. Simple, the same for every document, but it may cut through a table.

GrundschutzKI: at every heading, because the BSI standards are clearly structured. A chunk keeps its title. Docling ships several such chunkers.

READING DOCUMENTS

NOTEBOOK 2 · 10 MIN

IN THIS NOTEBOOK

- Convert the three papers with Docling, page by page
- See a table come through as a table
- Cut the pages into chunks, and look where the cuts land

YOUR TURN · IN THE CHATBOT

- 1 Where are the cuts? Send the first three chunks
- 2 Only the tables: send every table Docling found
- 3 If time: show the original PDF next to it

Solutions are folded away under each exercise.

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut



localhost:8000

 Schmidt_2022_SciReports.pdf

✓ Docling reads Schmidt_2022_SciReports.pdf

Schmidt_2022_SciReports.pdf: 10 pages, 54 chunks. This is page 1:

A multiparametric fluorescence assay for screening aptamer-protein interactions based on microbeads ...

WHAT WE FOUND SO FAR

Ask the room first,
then show the finding.

NOTEBOOK 1

Did the model know the Kage paper?

No, but it answered anyway: quantum dots, 2.5, 10 and 25 ns. The paper used organic dyes and quantum dots, 1.7 to 22.6 ns. A model doesn't know your documents, and doesn't say so.

NOTEBOOK 2

What did Docling do with the tables?

It kept all 5 tables in the three papers as Markdown tables, with their rows and columns, ready to be searched like any other text.

NOTEBOOK 2 · YOUR TURN

How big should a chunk be?

Size	Chunks	End mid-table
300	628	17
1000	197	5
3000	69	0

Small chunks find the exact passage but lose context; big ones keep tables whole but blur the match.

NEXT


We have good chunks. How do we find the right ones for a question? Embeddings.

EMBEDDINGS AND VECTOR SEARCH

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und RaumfahrtKI Service
Zentrum
by Hasso-Plattner-Institut

Similar meaning → arrows point the same way.



An **embedding model** turns text into 4096 numbers. Similar meaning, similar direction, even without shared words.

Collection “papers”

id	VECTOR	PAYLOAD
0	[0.012, -0.031, 0.087, ...]	Kage_2018 · p. 1 · “Time-res...”
1	[-0.007, 0.044, 0.019, ...]	Kage_2018 · p. 1 · “multiplex...”
2	[0.021, 0.003, -0.058, ...]	Kage_2018 · p. 2 · “are loade...”
... 203 points, one per chunk		

vector = what Qdrant searches by

payload = what you get back

query_points

Question → vector
embedded like the chunks

returns

5 closest points
each with score + payload

Qdrant stores one point per chunk: the vector to search by, and the payload you get back, with the text, the file and the page.

SEARCH

NOTEBOOK 3 · 13 MIN

IN THIS NOTEBOOK

- Embed sentences and compare how similar they are
- Store all chunks in Qdrant, in memory
- Turn the bot into a search engine, no LLM yet

YOUR TURN · IN THE CHATBOT

- 1 Fewer, better results: pick a score cutoff
- 2 Search one paper only: a dropdown and a filter
- 3 If time: open each hit as a PDF page

Solutions are folded away under each exercise.

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut

HPI

localhost:8000

What were the lifetime-encoded beads loaded with?

Kage_2018_SciReports.pdf, p. 2 (score 0.73)
› ... loaded with different organic fluorophores ...

Kage_2018_SciReports.pdf, p. 3 (score 0.64)
› Table 1. Lifetime codes and respective luminophores ...

What is the capital of France?

Kage_2018_SciReports.pdf, p. 6 (score 0.17) ...

PROMPT AND CITATIONS

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und RaumfahrtKI Service
Zentrum
by Hasso-Plattner-Institut

RETRIEVE

the 5 closest chunks

AUGMENT

the prompt with them, numbered [1] to [5]

GENERATE

the answer, citing those numbers

Every [n] leads back to a chunk, and every chunk remembers its file and page. That is all a citation is.

WHAT THE LLM RECEIVES

system

Answer only from the context. If it isn't there, say you don't know.

user

Context:

[1] ...microbeads are loaded with different organic...

[2] ...tailor-made melamine beads with a polyelectr...

⋮

[5] ...imitations of lifetime encoding in flow with...

Question: what were the beads loaded with?

LLM

gemma-4-31b

The beads were loaded
with different organic
fluorophores with
lifetimes in the
nanosecond range [1].

green: the 5 chunks Qdrant found · blue: what you typed

...loaded with different
organic fluorophores
in the nanosecond
range [1]

finds [1]

```
hits[0].payload
source: Kage_2018_...pdf
page: 2
```

cl.Pdf

opens at page 2

The number in the answer points into the list of chunks, and every chunk remembers its file and page.

RETRIEVAL-AUGMENTED GENERATION

NOTEBOOK 4 · 13 MIN

IN THIS NOTEBOOK

- Ask notebook 1's question again, this time with context
- Let the model cite the numbered chunks
- Turn every [n] into a link to the PDF page

YOUR TURN · IN THE CHATBOT

- 1 Strict or not: remove "say you don't know"
- 2 How much context: limit 2 versus 15
- 3 Show the evidence in the search step
- 4 If time: follow-up questions

Solutions are folded away under each exercise.

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut

HPI

localhost:8000

In Kage et al. (2018), what were the lifetime-encoded beads loaded with?

✓ Search the papers


PMMA beads stained with organic dyes from PolyAn GmbH [1], and melamine beads loaded with CdSe/CdS/ZnS quantum dots [1], [2].

Sources: Kage_2018_SciReports, p. 2

✓ Click the source: the PDF opens at page 2.

PUTTING IT TOGETHER

NOTEBOOK 5 · 10 MIN



One app.py with every piece. Attach a PDF in the chat and the top row runs live: read, chunk, embed, store. Then ask about it.

PIECE · NOTEBOOK

Read a PDF with Docling	2	Cut into chunks	2	Turn text into vectors	3
Store and search in Qdrant	3	Answer from the chunks	4	Cite the page	4

YOUR TURN · IN THE CHATBOT

- 1 Your own document: attach a PDF and ask
- 2 Chat with this document only: a Qdrant filter
- 3 If time: a dropdown to switch the model

Solutions are folded away under each exercise.

WHERE TO GO NEXT

Today	The template
PDFs only	Also txt, md, csv and json
Fixed 1000-character chunks	Structure-aware chunkers, chosen per data source in a config file
Qdrant in memory, rebuilt on every start	Qdrant server, ingested once, updated when files change
Vector search only	Hybrid search: vectors plus keyword matching
[1] and a file name	Citation format set in the config: title, file, page
You judge the answers by eye	An evaluation app that scores answers

THIS WORKSHOP

github.com/aihpi/workshop-rag-basics

THE TEMPLATE

github.com/aihpi/pilotproject-rag-template

OTHER EMBEDDING MODELS

huggingface.co/spaces/mteb/leaderboard

Gefördert durch:



YOUR FEEDBACK COUNTS

We shape our next workshops around your answers. Two minutes is enough.



kisz@hpi.de

hpi.de/kisz

[Presenter]

KEEP GOING

github.com/aihpi/workshop-rag-basics · this workshop

github.com/aihpi/pilotproject-rag-template · template

**Design IT.
Create Knowledge.**

www.hpi.de

